

# Q-Learning

## 概要

Q-learning 是一种 **model-free 的强化学习** 和 **异步动态规划 (asynchronous dynamic programming)** 方法, 使智能体能够在 **受控 Markov** 环境中学习如何最优行动。所谓的 **Q** 就是 (state, action), 状态-动作对, Q-Learning 的目标就是 **对每个状态动作对打分, 然后不断修正这个分数**。论文证明了 Q-Learning 会以概率 1 收敛到最优 Action Value。

### Contributions:

- Q-Learning 收敛性证明
- Q-Learning 系统化描述
- 讨论其拓展形式

#### 📌 Note

##### 受控 Markov 环境

普通的 Markov 链状态转移概率  $P(s'|s)$  固定, 例如

Sunny  $\rightarrow$  Rainy = 0.3   Sunny  $\rightarrow$  Sunny = 0.7

这就是标准的 Markov Process

而论文中的 Controlled Markov Process 加入了智能体

状态  $s$  时, agent 选择了动作  $a$ , 环境发生了变化, 状态转移到了  $s'$

此时的状态转移变成了  $P(s'|s, a)$

这就是 **控制马尔可夫过程** 或者现在更常见的称呼 **Markov Decision Process (MDP)**

#### 📌 Note

##### 异步动态规划

想了解异步动态规划, 首先我们先要了解什么是 **同步动态规划 (Synchronous DP)**

举个例子

$$V_{k+1}(s) = \max_a [R + \gamma \sum P(s'|s, a) V_k(s')]$$

$s$  是一组状态  $\{s_1, s_2, s_3, \dots, s_n\}$ , 每次根据更新规则这一组状态总是同时被更新, 这就是同步的含义

问题在于, 现实中状态空间巨大, 比如围棋约有  $10^{170}$  个状态, 这时我们不可能全部更新再进行下一轮

异步动态规划应运而生, 在同步动态规划的基础上, 每个状态不再同时被更新, 而是 **访问到谁更新谁**

# The Task for Q-Learning

## 任务描述

考虑一个智能体，生活在一个 **离散且有限的** 世界中，每个时间步都从 **有限动作** 中选择一个动作。

在时间步  $n$ ,

1. agent 观察状态  $x_n$
2. 选择动作  $a_n$
3. 获得随机奖励  $r_n$  并根据一定的 **Transition Probability** 进入新的状态  $y_n$

$$Prob[y_n = y | x_n, a_n] = P_{x_n y}[a_n] = P(s' | s, a) \quad (1)$$

Agent 的目标是寻找最优策略，使长期折扣奖励最大

$$V^\pi(x) = R_x(\pi(x)) + \gamma \sum_y P_{xy}[\pi(x)] V^\pi(y) \quad (2)$$

这就是 **Bellman Equation**，状态价值 = 立即奖励 + 未来状态价值

只不过对未来状态价值我们添加了一个 discount  $\gamma$

## 最优价值函数

动态规划理论保证，在有限 MDP（状态有限，动作有限）的情况下一定有最优策略  $\pi$

### Bellman Optimality Equation

$$V^*(x) = \max_a (R_x(a) + \gamma \sum_y P_{xy}[a] V^*(y)) \quad (3)$$

### Q 函数

$$Q^\pi(x, a) = R_x(a) + \gamma \sum_y P_{xy}[a] V^\pi(y) \quad (4)$$

其实看的出来 Bellman Equation 和 Q 函数差距并不大，只是他们描述的对象不一样

前者告诉你当前状态有多好，后者告诉你在这个状态  $x$  下，动作  $a$  有多好。

因此作者提出：强化学习问题可以转化为学习 Q 函数的问题，无需直接学习策略和环境，只通过学习 Q 来解决强化学习问题，然后最优策略就可以表示为

$$\pi^*(s) = \arg \max_a Q(s, a)$$

## Q 的更新方式

$$Q_n(x, a) = \begin{cases} (1 - \alpha_n)Q_{n-1}(x, a) + \alpha_n [r_n + \gamma V_{n-1}(y_n)], & \text{if } x = x_n \text{ and } a = a_n, \\ Q_{n-1}(x, a), & \text{otherwise.} \end{cases} \quad (4)$$

where

$$V_{n-1}(y) \equiv \max_b \{Q_{n-1}(y, b)\} \quad (5)$$

拆开来看，实际上可以简单的理解成

$$Q_{new} = (1 - \alpha)Q_{old} + \alpha Target$$

而  $Target$  正是 Bellman Equation (2) 的右半部分

那到达了新状态  $y$  之后怎么办？作者在公式 (5) 给出了解释：假设未来永远选最优动作（Greedy）

### ① Note

#### Off-Policy

Q-Learning 被广泛的认为是 off-policy，我们简单介绍一下 off-policy 和 on-policy 是什么意思

强化学习中两个概念

- **行为策略 Behavior Policy** 怎么行动
- **目标策略 Target Policy** 希望学成什么样

off-policy 的意思就是说 **行为策略**  $\neq$  **目标策略**，反之则是 on-policy

公式 (5) 正是导致 Q-Learning 是 off-policy 的原因：

不管以前 Agent 实际执行了什么 Action，

Q-Learning 在更新时都假设：从下一状态开始，未来每一步都选择当前 Q 最大的 Action。

## 收敛性讨论

收敛性条件

- 收敛最重要的条件：**对每个状态动作对，都必须被访问无限次**
- 作者也提出：在随机环境下，任何方法都无法在更弱条件下保证找到最优策略  
简单来说，如果不访问所有 state-action pair，就没有信息，所以**必须访问所有 state-action pair**
- **经验不必连续**，零碎的离散的经验也可以训练

## 结论

$$Q_n(x, a) = \begin{cases} (1 - \alpha_n)Q_{n-1}(x, a) + \alpha_n[r_n + \gamma V_{n-1}(y_n)], & \text{if } x = x_n \text{ and } a = a_n, \\ Q_{n-1}(x, a), & \text{otherwise.} \end{cases} \quad (4)$$

作者不仅证明了  $Q_n(x, a) \rightarrow Q^*(x, a)$  而且他还证明了 **所有的 state-action pair 的 Q 值都收敛到最优动作价值**

## 条件

这个结论有三个条件（对照公式 (4)）

1. **Reward 有界**  $|r_n| \leq R$  否则 Q 也将变得无界
2. 学习率  $0 < \alpha_n < 1$ , 并且

$$\sum_i \alpha_{n_i(x,a)} = \infty$$

意思是说  $\alpha$  的和是发散的, 虽然学习率越来越小, 但是不能完全消失 ( $\alpha \approx 0$ )

3. 平方和必须收敛

$$\sum_i \alpha_{n_i(x,a)}^2 < \infty$$

累计噪声方差收敛

## 证明

根据公式 (4) 不难发现一个问题:  $Q_n$  每一步都在变化, 而且  $r_n, y_n$  随机。这使得直接证明非常困难  
聪明的作者没有直接研究  $Q_n$ , 而是用了一个小巧思: **有没有一个 MDP, 它的最优 Q 值刚好等于  $Q_n$**

读到这里, 相信读者会很困惑, 这么做有什么意义。

但是作者说年轻人不要太急, 把你拉住对你说 "You have no cards", 并递给你了一堆牌



你翻开牌一看，发现作者是这么设计牌的：

- 把训练历史  $(x_t, a_t, y_t, r_t)$  表示成卡牌
- 把所有的历史经验堆成了牌堆

## Action Replay Process (APR)

作者提出了这个新过程。APR 的状态定义为

$$(x, n)$$

其中：

- $x$  是原 MDP 的状态
- $n$  是卡片编号（并非时间步，而是第  $n$  张卡，且只允许使用前  $n$  张经验卡，当前位于状态  $x$ ）

这么构造的目的是将  $Q_n(x, a)$  中的  $n$  编码进状态空间，证明的目标又转换为了

$$Q^*(x, a) = Q_n(x, a) = Q_{APR}^*((x, n), a) \quad (6)$$

### 状态转移

1. 假设当前  $(x, n)$  执行动作  $a$ ，
2. APR 不去访问真实环境，而是在历史经验里查询 **最近一次出现  $(x, a)$  的经验**
3.  $\text{reward} = (x, a)$ （即第  $a$  次）记录的奖励
4. 下一状态 =  $(x, a)$ （即第  $a$  次）记录的下一状态

这也是作者称之为 **Replay** 的原因：只从历史经验中回放

当然这一部分证明跟强化学习就没什么太多关系了，我们就不在此严格的分析证明了，总的来说

**ARP 把 Q-Learning 的学习历史包装成一个 MDP，然后利用已有的 DP 理论来证明 Q-Learning 收敛。**